Байесовский классификатор. Оценка плотности распределения.

Евгений Борисов

Х - объекты, Ү - метки классов

$$X\!\! imes\!\!Y$$
- вероятностное пространство с плотностью $p(x,y)$

выборка:
$$(X' \times Y') \subset (X \times Y)$$

Задача: построить классификатор с минимальной ошибкой

$$a: X' \rightarrow Y'$$

принцип максимума апостериорной вероятности

$$a(x) = \underset{y \in Y}{argmax} P(y|x)$$

принцип максимума апостериорной вероятности

$$a(x) = \underset{y \in Y}{argmax} P(y|x)$$

формула Байеса:

$$P(A|B) = \frac{P(A)P(B|A)}{P(B)}$$

байесовский классификатор

$$a(x) = \underset{y \in Y}{\operatorname{argmax}} \lambda_{y} P(y) p(x|y)$$

 λ_v - потеря для объектов у

 $P(\,y)$ - доля примеров класса у (априорная вероятность)

$$p(x|y)$$
- плотность класса у

подходы к оценке плотности распределения

- непараметрический
- параметрический
- смеси распределений

Восстановление плотности

подходы к оценке плотности распределения:

параметрический подход

$$\hat{p}(x) = \varphi(x, \theta)$$

НЕпараметрический подход

$$\hat{p}(x) = \frac{1}{m V(h)} \sum_{j=1}^{m} K\left(\frac{\rho(x, x_j)}{h}\right)$$

смеси распределений

$$\hat{p}(x) = \sum_{j=1}^{k} w_j \varphi_j(x, \theta_j)$$

«наивный Байес»

допущение: признаки X - независимы друг от друга

тогда многомерную плотность можно представить как произведение одномерных плотностей

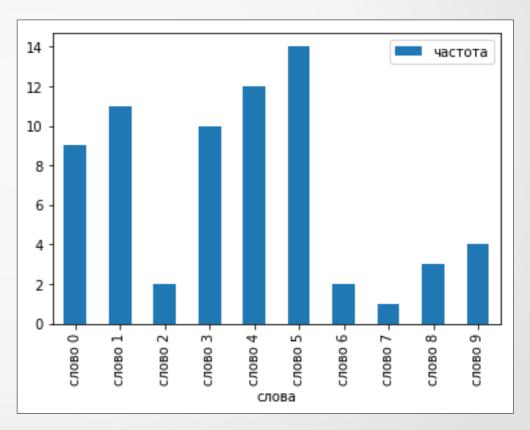
$$p(x|y) = p_1(x_1|y)...p_n(x_n|y)$$

Восстановление плотности

НЕпараметрический подход

дискретный случай: гистограмма

$$\hat{p}(x) = \frac{1}{m} \sum_{i=1}^{m} [x = x_i]$$



пример: распределение повторов слов в тексте

непараметрические методы оценки плотности распределения

непрерывный случай: эмпирическая оценка, окно ширины h (доля объектов попавших в отрезок)

$$\hat{p}(x) = \frac{1}{2hm} \sum_{i=1}^{m} [|x - x_i| < h]$$

$$\hat{p}(x) = \frac{1}{mh} \sum_{i=1}^{m} \frac{1}{2} \left[\frac{|x - x_i|}{h} < 1 \right]$$

оценка Парзена-Розенблата для класса у

$$\hat{p}(x|y) = \frac{1}{L_y V(h)} \sum_{i:y=y_i} K\left(\frac{\rho(x, x_i)}{h}\right)$$

$$K(r)$$
 - ядро

 $L_{_{\scriptscriptstyle y}}$ - количество объектов у

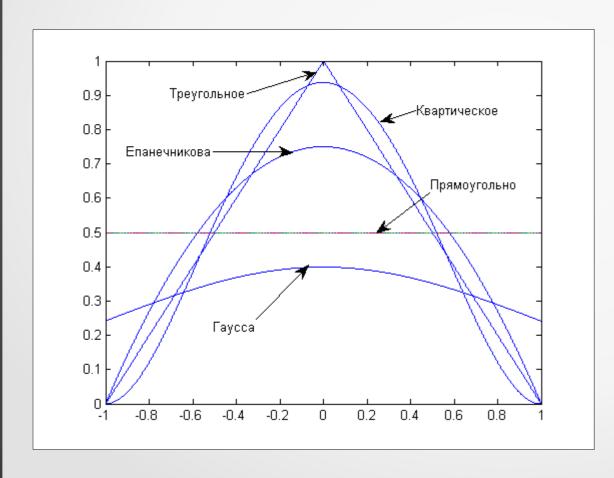
$$ho(x_i,x_i)$$
 - мера на Х

V(h) - нормирующий множитель

Восстановление плотности

функции ядра для сглаживания гистограммы

KDE, Kernel Density Estimation



чётная ф-ция

$$K(r)=K(-r)$$

нормированная

$$\int K(r)dr = 1$$

невозрастающая при r>0, неотрицательная ф-ция

ядро Епанечникова:

$$K(r) = \frac{3}{4}(1-r^2); |r| \le 1$$

Восстановление плотности


непараметрические методы:


оценка плотности Парзена-Розенблата

ядерное сглаживание (гистограммы)

KDE, Kernel Density Estimation

$$\hat{p}(x) = \frac{1}{m V(h)} \sum_{i=1}^{m} K\left(\frac{\rho(x, x_i)}{h}\right)$$





$$a(x) = \underset{y \in Y}{\operatorname{argmax}} \lambda_{y} P(y) p(x|y)$$

Байесовский классификатор, метод Парзеновского окна

$$a(x, X^{L}, h) = \underset{y \in Y}{argmax} \lambda_{y} P(y) \frac{1}{L_{y}} \sum_{i: y = y_{i}} K\left(\frac{\rho(x, x_{i})}{h}\right)$$

оценка плотности - параметрический подход

$$\hat{p}(x) = \varphi(x, \theta)$$

оценка плотности - параметрический подход

$$\hat{p}(x) = \varphi(x, \theta)$$

принцип максимума правдоподобия

$$L(\theta, X) = \sum_{i=1}^{m} \ln \varphi(x_i, \theta) \rightarrow \max_{\theta}$$

оценка плотности - параметрический подход

$$\hat{p}(x) = \varphi(x, \theta)$$

принцип максимума правдоподобия

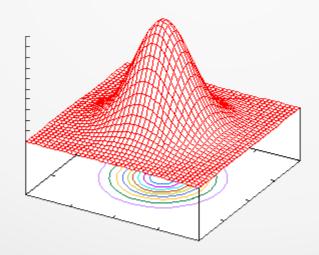
$$L(\theta, X) = \sum_{i=1}^{m} \ln \varphi(x_i, \theta) \rightarrow \max_{\theta}$$

условие оптимума

$$\frac{\partial}{\partial \theta} L(\theta, X) = \sum_{i=1}^{m} \frac{\partial}{\partial \theta} \ln \varphi(x_i, \theta) = 0$$

допущение: классы имеют n-мерную нормальную плотность

$$p(x|y) = \frac{\exp\left(-\frac{1}{2}(x - \mu_y)^T \Sigma_y^{-1}(x - \mu_y)\right)}{\sqrt{(2\pi)^n \det \Sigma_y}}; y \in Y$$



Теорема: параметры оценки максимального правдоподобия для n-мерных гауссовских плотностей классов у имеют следующий вид

$$\hat{\mu}_{y} = \frac{1}{l_{y}} \sum_{i: y = y_{i}} x_{i} \qquad \hat{\Sigma}_{y} = \frac{1}{l_{y}} \sum_{i: y = y_{i}} (x_{i} - \hat{\mu}_{y}) (x_{i} - \hat{\mu}_{y})^{T}$$

Теорема: параметры оценки максимального правдоподобия для n-мерных гауссовских плотностей классов у имеют следующий вид

$$\hat{\mu}_{y} = \frac{1}{l_{y}} \sum_{i: y = y_{i}} x_{i} \qquad \hat{\Sigma}_{y} = \frac{1}{l_{y}} \sum_{i: y = y_{i}} (x_{i} - \hat{\mu}_{y}) (x_{i} - \hat{\mu}_{y})^{T}$$

Байесовский классификатор: квадратичный дискриминант

$$a(x) = \underset{y \in Y}{\operatorname{argmax}} \left(\ln(\lambda_{y} P_{y}) - (x - \hat{\mu}_{y})^{T} \hat{\Sigma}_{y}^{-1} (x - \hat{\mu}_{y}) - \frac{1}{2} \ln(\det \hat{\Sigma}_{y}) \right)$$

Дополнение:

если матрицы ковариаций классов равны то параметры оценки плотности имеют следующий вид

$$\hat{\mu}_{y} = \frac{1}{l_{y}} \sum_{i:y=y_{i}} x_{i} \qquad \hat{\Sigma} = \frac{1}{l} \sum_{i=1}^{l} (x_{i} - \hat{\mu}_{yi}) (x_{i} - \hat{\mu}_{yi})^{T}$$

Дополнение:

если матрицы ковариаций классов равны то параметры оценки плотности имеют следующий вид

$$\hat{\mu}_{y} = \frac{1}{l_{y}} \sum_{i: y = y_{i}} x_{i} \qquad \hat{\Sigma} = \frac{1}{l} \sum_{i=1}^{l} (x_{i} - \hat{\mu}_{yi}) (x_{i} - \hat{\mu}_{yi})^{T}$$

Байесовский классификатор: линейный дискриминант Фишера

$$a(x) = \underset{y \in Y}{argmax} \left(\ln(\lambda_{y} P_{y}) - \frac{1}{2} \hat{\mu}_{y}^{T} \hat{\Sigma}^{-1} \hat{\mu}_{y} + x^{T} \hat{\Sigma}^{-1} \hat{\mu}_{y} \right)$$

git clone https://github.com/mechanoid5/ml_lectorium.git

К.В. Воронцов Байесовская теория классификации и методы восстановления плотности. - Курс "Машинное обучение" ШАД Яндекс 2014

Борисов Е.С. Байесовский классификатор. http://mechanoid.su/ml-bayes.html