



# **Автоматическая обработка текстов на естественном языке. Тематическое моделирование.**

Евгений Борисов

# NLP Тематическое моделирование

## **Тематическое моделирование**

автоматическое извлечение тем из набора текстов

наборы ключевых слов

# NLP Тематическое моделирование

## Тематическое моделирование

$W$  - конечное множество слов

$D$  - конечное множество документов

$T$  - конечное множество тем

# NLP Тематическое моделирование

## Тематическое моделирование

$W$  - конечное множество слов

$D$  - конечное множество документов

$T$  - конечное множество тем

слово  $w$  в документе  $d$  связано с темой  $t$

$D \times W \times T$  - дискретное вероятностное пространство

порядок слов в документе не важен

$d, w$  - наблюдаемые,  $t$  - скрытая

# NLP Тематическое моделирование

## Тематическое моделирование

$W$  - конечное множество слов

$D$  - конечное множество документов

$T$  - конечное множество тем

слово  $w$  в документе  $d$  связано с темой  $t$

$D \times W \times T$  - дискретное вероятностное пространство

порядок слов в документе не важен

$d, w$  - наблюдаемые,  $t$  - скрытая

гипотеза независимости  $p(w|d,t) = p(w|t)$

# NLP Тематическое моделирование

## Тематическое моделирование

$W$  - конечное множество слов

$D$  - конечное множество документов

$T$  - конечное множество тем

слово  $w$  в документе  $d$  связано с темой  $t$

$D \times W \times T$  - дискретное вероятностное пространство

порядок слов в документе не важен

$d, w$  - наблюдаемые,  $t$  - скрытая

гипотеза независимости  $p(w|d,t) = p(w|t)$

гипотеза разреженности - документ  $d$  и термин  $w$  связаны с небольшим числом тем  $t$ , значительная часть вероятностей  $p(t|d)$  и  $p(w|t)$  должна обращаться в нуль.

# NLP Тематическое моделирование

## Тематическое моделирование

слово  $w$  в документе  $d$  связано с темой  $t$

$d, w$  - наблюдаемые,  $t$  - скрытая

гипотеза независимости  $p(w|d,t)=p(w|t)$

гипотеза разреженности - документ  $d$  и термин  $w$  связаны с небольшим числом тем  $t$ , значительная часть вероятностей  $p(t|d)$  и  $p(w|t)$  должна обращаться в нуль.

тематическая модель:

$$p(w|d) = \sum_t p(w|t)p(t|d)$$

# NLP Тематическое моделирование

## Тематическое моделирование

Выполняем частотный анализ (TF)

матрица частот употребления слова  $w$  в документе  $d$

[ слова x документы ]

вероятность  $p(w|d)$  "слово  $w$  принадлежит документу  $d$ ".  
можно оценивать как частоту слова



# NLP Тематическое моделирование

## Тематическое моделирование

разложение частотной матрицы

$$[ \text{слова} \times \text{документы} ] = [ \text{слова} \times \text{темы} ] * [ \text{темы} \times \text{документы} ]$$

$$p(w|d) = p(w|t) \cdot p(t|d)$$

$p(w|t)$  - матрица с описанием тем [ слова x темы ]  
или оценки вероятностей "слово  $w$  принадлежит теме  $t$ ",

$p(t|d)$  - матрица [ темы x документы ],  
или оценки вероятностей "тема  $t$  описывает документ  $d$ ".

# NLP Тематическое моделирование

## Тематическое моделирование

разложение частотной матрицы

$$[ \text{слова} \times \text{документы} ] = [ \text{слова} \times \text{темы} ] * [ \text{темы} \times \text{документы} ]$$

$$p(w|d) = p(w|t) \cdot p(t|d)$$

## задача стохастического матричного разложения

**стохастическая матрица** — неотрицательная, сумма любого столбца/строки = 1

методы решения

PLSA - probabilistic latent semantic analysis

LDA - latent Dirichlet allocation / латентное размещение Дирихле

NMF - non-negative matrix factorization / неотрицательная матричная факторизация

# NLP Тематическое моделирование

## примеры текстов

Около 18 тысяч человек покинули подконтрольные боевикам районы Алеппо. За минувшие сутки из подконтрольных боевикам районов сирийского города Алеппо было выведено около 17,971 тысячи жителей, в их числе 7,542 тысячи детей. Об этом в субботу, 10 декабря, сообщает ТАСС со ссылкой на российский Центр примирения враждующих сторон в Арабской Республике.

Лидер Радикальной партии Украины Олег Ляшко назвал Надежду Савченко госизменницей. Политик призвал лишить наводчицу мандата народного депутата "То, что сейчас чудит Савченко, – это государственная измена. За подобные действия ей надо немедленно запретить доступ к государственной тайне, отозвать из ПАСЕ и лишить мандата народного депутата Украины", – написал Ляшко на странице в Facebook.

Финальная распродажа! Chery Tiggo от 19990 руб (199,9 млн) «Китайские автомобили» объявляют финальную распродажу популярных кроссоверов Chery Tiggo FL! На автомобили в максимальной комплектации установлена специальная цена 19 990 рублей (199,9 млн). Количество автомобилей ограничено!

# NLP Тематическое моделирование

## Темы и ключевые слова

Тема 0: рублей млн компания компании млрд модели долларов

Тема 1: трамп сша трампа дональд президент избранный президента

Тема 2: by tut декабря фото беларуси ноября беларусь

Тема 3: дтп водитель результате мвд области происшествия аварии

Тема 4: савченко украины надежда заявила партии лидер действия

Тема 5: народов севера коренных малочисленных края фестиваль июля

Тема 6: ученые университета специалисты исследователи жизни часов человека

Тема 7: flash adobe player javascript браузер проигрывателя html5

Тема 8: россия путин рф президент заявил глава президента

Тема 9: динамо матче чемпионата очков матча лиги шахтера

# NLP Тематическое моделирование

## Литература

git clone [https://github.com/mechanoid5/ml\\_lectorium](https://github.com/mechanoid5/ml_lectorium)

К.В. Воронцов Вероятностные тематические модели коллекций текстовых документов.

Евгений Борисов Автоматизированная обработка текстов на естественном языке, с использованием инструментов языка Python  
<http://mechanoid.su/ml-text-proc.html>

Евгений Борисов О задаче определения темы текста на естественном языке  
<http://mechanoid.su/ml-topic-modeling.html>

Sebastian Raschka Python Machine Learning - Packt Publishing Ltd, 2015